噪声语义提示分布驱动的SAM2轻量适配用于光学遥感显著性检测

Noise-Prompt Distribution-Aware Lightweight Adaptation of SAM2 for Salient Object Detection in Optical Remote Sensing Images

摘要

【目的】 多模态大语言模型（MLLM）能够从光学遥感图像中识别潜在显著地物并生成粗框，但其提示同时包含目标选择错误、实例遗漏和范围偏差；通用分割基础模型直接使用这些提示时还存在明显遥感域差距。本文研究如何在保留冻结MLLM语义能力的同时，利用公开训练划分的像素标注对SAM2进行轻量校准，使分割器适应真实MLLM提示分布。

【方法】 冻结DeepSeek视觉模型离线生成显著性命题、类别和候选框。本文仅从ORSSD、EORSSD和ORSI-4199的训练划分统计MLLM提示与真值组件之间的偏移、尺度和命中关系，据此构造包含命中型与偏移型框的训练提示。冻结SAM2.1 base+的图像编码器和提示编码器，只更新4.22M参数的掩码解码器；训练时按SAM2自报质量分选择候选，并以多提示预测并集学习整图显著掩码。该监督主分支记为NPA-SAM。为说明标注成本边界，另保留无需当前任务训练的PRISM分支，通过类别一致性、掩码反馈和面积守卫修复冻结SAM2的输入提示。

【结果】 NPA-SAM在ORSSD、EORSSD和ORSI-4199上的两种子平均Sα分别为 **0.9216、0.9031和0.8596**，三集等权平均为 **0.8948**。冻结SAM2直接使用原始MLLM框的宏平均为0.7618，无任务训练PRISM将其提高至0.7845。仅使用另外两个数据集训练、在留出数据集上评测时，三折Sα为0.9016、0.8799和0.8317，宏平均0.8711。测试真值框oracle在同一解码器上的宏平均为0.9151，比真实MLLM框高2.03点，说明提示仍有改进空间，但剩余误差不能全部归因于提示。对2,999张测试图的6,266个框进行事后分析，47.2%的框与某个真值组件外接框IoU不低于0.5，32.1%的框最佳IoU低于0.1。

【结论】 与继续扩大冻结主干相比，使轻量解码器接触真实MLLM式提示噪声是提高遥感显著性分割质量的更有效路径。本文的主要贡献是将提示可靠性测量、训练分布构造和SAM2参数高效校准连接为一条可复核流程；PRISM则作为无任务训练条件下的低成本变体。现有结果仍低于强全监督专用网络，后续提升应优先面向实例级提示分配和编码器后层的参数高效域适配。

关键词：光学遥感；显著性目标检测；多模态大语言模型；SAM2；提示噪声；参数高效适配

Abstract

Objective. Multimodal large language models (MLLMs) can identify potentially salient entities in optical remote sensing images and produce coarse boxes. These prompts, however, contain target-selection errors, missed instances, and inaccurate extents, while generic segmentation foundation models also exhibit a domain gap on remote sensing imagery. We study lightweight adaptation of SAM2 to the empirical distribution of noisy MLLM prompts using pixel annotations from public training splits.

Methods. A frozen DeepSeek vision model generates saliency propositions, categories, and candidate boxes offline. Prompt-to-component offsets, scales, and matching relations are estimated only from the training splits of ORSSD, EORSSD, and ORSI-4199. The resulting distribution is used to sample hit-type and offset-type prompts. The image and prompt encoders of SAM2.1 base+ are frozen, and only the 4.22M-parameter mask decoder is optimized. During training, mask candidates are selected using SAM2-reported quality scores, and the union of multi-prompt predictions is supervised by the full-image saliency mask. We call this supervised branch NPA-SAM. A separate training-free PRISM branch repairs prompts for frozen SAM2 using category consistency, mask feedback, and an area guard.

Results. NPA-SAM obtains two-seed average S-measures of **0.9216, 0.9031, and 0.8596** on ORSSD, EORSSD, and ORSI-4199, respectively, with an equal-dataset mean of **0.8948**. Frozen SAM2 with raw MLLM boxes obtains

0.7618, while training-free PRISM improves it to 0.7845. Leave-one-dataset-out training yields 0.9016, 0.8799, and 0.8317, averaging 0.8711. Ground-truth boxes raise the same calibrated decoder from 0.8948 to 0.9151, leaving 2.03 S-measure points attributable to prompt-side headroom. Among 6,266 boxes from 2,999 test images, 47.2% reach a box IoU of at least 0.5 with a ground-truth component, whereas 32.1% have a best IoU below 0.1.

Conclusion. Exposing a lightweight decoder to realistic MLLM-style prompt noise is more effective than merely enlarging a frozen segmentation backbone. The main contribution is a traceable connection among prompt reliability measurement, training-distribution construction, and parameter-efficient SAM2 calibration. PRISM remains a low-cost alternative when task-specific training is unavailable.

Keywords: optical remote sensing; salient object detection; multimodal large language model; SAM2; prompt noise; parameter-efficient adaptation

1 引言

1.1 问题背景

光学遥感显著性目标检测（ORSI-SOD）要求模型在复杂俯视场景中确定视觉主体并输出像素级掩码。目标尺度跨度、任意方向、密集实例、低对比度和复杂背景使得自然图像显著性模型难以直接迁移。MCCNet[1]通过前景、边缘、背景和全局内容互补改善结构表达，GeleNet[2]利用Transformer建立全局依赖并强化方向和跨层关系，SAM2-RS[3]进一步说明对基础分割模型进行参数高效域适配能够获得较高精度，IPDiff[4]则通过迭代扩散细化突破一次前向预测的限制。

MLLM与分割基础模型提供了另一种分工：MLLM回答“什么显著、在哪里”，分割模型负责像素执行。该范式能显式引入语义判断，但其有效性取决于提示可靠性。遥感图像中的粗框可能选择背景目标、覆盖多个实例、漏掉小目标或与不规则地物范围不一致。若分割器始终把每个框当作正确提示，提示错误会直接转化为假前景；若只依赖人工规则删框，又可能破坏多类别显著场景。

本文最初从完全冻结设置研究提示修复，但实验显示，任务训练是缩小最终精度差距的主要因素：冻结SAM2与完整PRISM的宏平均Sα为0.7845，而只训练4.22M参数的掩码解码器即可达到0.8948。与此同时，简单把冻结分支的全部规则叠加到训练后解码器并不可靠，完整PRISM反而使宏平均下降0.33点。因此，本文将核心问题重新表述为：**如何利用训练划分中的提示误差统计，使轻量SAM2解码器适应真实MLLM提示，同时保留无任务训练条件下的可部署退化版本？**

1.2 主要贡献

1. **遥感MLLM提示的量化诊断。** 在三个公开数据集的2,999张测试图上分析6,266个候选框，给出严格匹配、严重失配、像素覆盖和类别关系等统计，并区分事后诊断与推理可用信息。
2. **噪声提示分布驱动的轻量适配。** 仅从训练划分估计提示误差分布，按真实框形态采样训练提示；冻结SAM2图像编码器与提示编码器，只更新4.22M参数的掩码解码器。该设计把训练输入从理想GT框附近扰动推进到更接近真实MLLM提示的分布。
3. **监督成本和组件交互的系统边界。** 以NPA-SAM作为监督主方法，以PRISM作为无任务训练变体，并通过留一数据集迁移、几何提示对照、GT框oracle和匹配消融说明提示信息、域内标注及规则修复各自的作用。

1.3 监督协议

本文严格区分三种设置。主结果使用公开训练划分的像素掩码，属于域内监督适配；跨域设置只使用另外两个源数据集的训练标注；无任务训练设置不更新任何当前任务参数。GT提示oracle读取测试真值，仅用于误差分解，不属于可部署结果。

设置	训练时使用的标注	目标域训练掩码	更新参数	论文角色
NPA-SAM域内适配	三个公开训练划分的像素掩码	是	SAM2掩码解码器4.22M	监督主方法
留一数据集迁移	仅另外两个源域训练掩码	否	SAM2掩码解码器4.22M	泛化分析
冻结SAM2+PRISM	无当前任务训练标注	否	0	低成本变体
GT框oracle	推理读取测试GT框	是	使用已训练解码器	诊断上界

现有域内结果采用三个数据集共4,000张训练图联合训练，并非主流方法常用的“每个数据集单独训练”协议。因此，本文对外部全监督方法只报告性能位置，不将联合训练结果表述为同协议严格排名。ORSSD与EORSSD之间还需在投稿前完成像素哈希和感知哈希重复审计；若发现目标测试图出现在其他数据集训练划分中，应删除重叠样本并重新训练。

2 相关工作

2.1 光学遥感显著性检测

卷积方法通常利用多尺度融合、边缘监督和背景抑制处理遥感场景。MCCNet[1]显式构造前景、边缘、背景和全局内容之间的互补关系。Transformer方法进一步利用全局依赖，GeleNet[2]以PVT为主干，通过方向感知局部增强和跨层知识传递处理任意方向、细结构和多实例目标。近期SAM2-RS[3]在SAM2编码器中插入双适配器，并配合多尺度解码器进行遥感域适配。IPDiff[4]将显著性检测建模为条件扩散过程，以多重先验引导迭代去噪。这些方法共同表明，领域特征适配、边界表达和多尺度解码是提高ORSI-SOD精度的重要条件。

2.2 MLLM提示与基础模型分割

SAM2[7]能够根据框、点或掩码提示输出高质量候选，但本身不负责判断遥感图像中哪个对象应被视为显著。FOCUS[5]和Saliency-R1[6]等工作从观察协议、语义推理或多模态模型训练角度研究显著性。本文不把“MLLM+SAM2”的组合本身作为创新，而把重点放在两个连接环节：第一，测量冻结MLLM提示在遥感域中的真实误差；第二，使轻量解码器在训练阶段接触与推理阶段相近的提示分布。

2.3 参数高效适配与提示噪声

完整微调基础模型成本较高，也可能破坏预训练表征。SAM2-RS[3]证明少量适配参数即可显著改善遥感显著性检测。与其直接在编码器内加入多个领域模块不同，本文现阶段冻结图像与提示编码器，只训练原有掩码解码器，并把建模重点放在输入提示的经验噪声分布。该选择便于在有限显存条件下训练，也使提示质量和解码能力能够分别诊断。

3 方法

3.1 总体框架

如图1，系统由离线语义提示、噪声分布构造、SAM2轻量适配和可选的冻结提示修复组成。MLLM提示库只生成一次；监督主分支NPA-SAM从训练划分估计提示误差并训练掩码解码器，推理时直接读取原始MLLM框。无任务训练分支不加载适配权重，通过PRISM修复提示后交给冻结SAM2。两条分支共享MLLM提示来源，但其最优提示处理不同，不能假定规则修复和学习型校准可以无条件叠加。

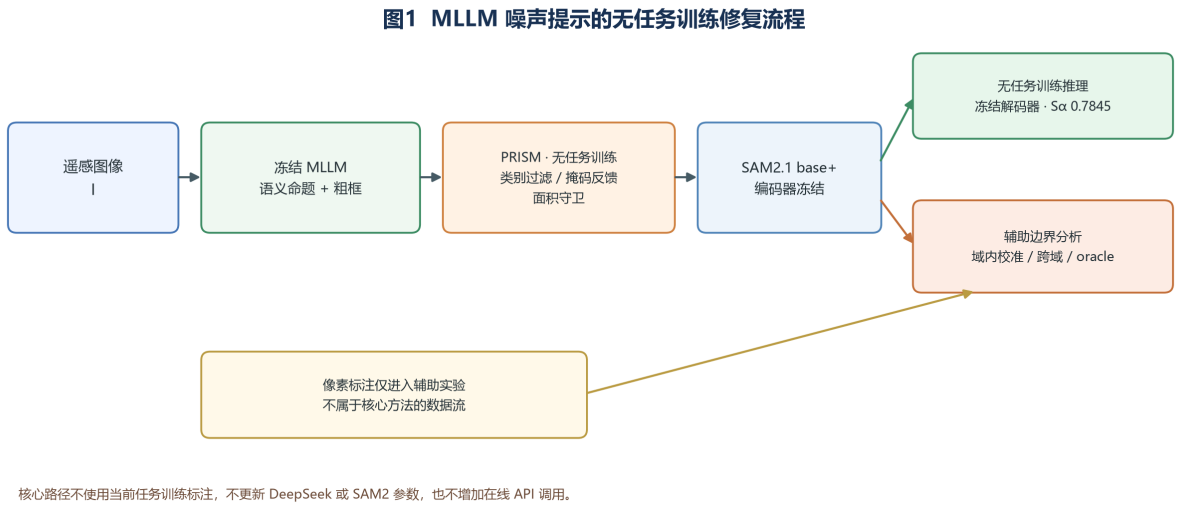


图1：冻结提示修复与监督轻量适配的双分支框架

3.2 冻结MLLM提示生成

第一阶段要求冻结视觉语言模型给出显著性命题和类别，第二阶段根据该命题输出归一化候选框。离线记录中的模型标识为deepseek-v4-flash-vision-exp，温度为0，类别词表包含15类，每幅图最多5个实例。测试提示库覆盖2,999张图，训练提示库覆盖4,000张图。下游训练和评测均读取固定JSON记录，不在推理时重新调用API。

温度为0只能提高单一服务版本下的运行一致性，不能保证云端模型升级后的字节级复现。因此公开材料应包含模型标识、提示模板、调用日期、原始回复和解析器版本。

3.3 训练集提示误差建模

对训练划分中的每个MLLM框，与GT连通域外接框计算最大IoU，并记录框中心偏移、宽高尺度比、命中状态和类别。所有统计只从训练划分产生，测试GT不参与最终配方。根据经验分布，每幅训练图采样1个命中型提示和2个偏移型提示；命中型框模拟覆盖目标但范围不准的情况，偏移型框模拟真实MLLM提示中的位置和尺度误差。

与只在GT框附近进行固定比例抖动相比，该采样方式包含更宽的形态变化。训练时使用SAM2自报质量分选择候选，与推理阶段保持一致。多个提示对应的预测掩码取并集，再与整幅GT计算损失。需要强调：在现有实现中，偏移提示并未逐个匹配GT组件，也不能把每个偏移框描述为独立空掩码监督；实例级分配属于后续改进方向。

3.4 NPA-SAM轻量适配

NPA-SAM采用SAM2.1 base+。图像编码器和提示编码器完全冻结，只训练sam_mask_decoder，可训练参数量为4.22M。训练数据为三个数据集训练划分共4,000张原图，训练3个epoch，随机种子为42和43。正样本优化采用二元交叉熵与IoU损失的组合；最终报告两种子的逐数据集平均。

训练候选选择和推理均采用SAM2自报质量分，避免训练时用GT挑选最佳候选而推理时无法复现。推理阶段使用原始MLLM框，因为匹配消融表明，掩码反馈在适配后解码器上产生负交互；类别过滤虽有正增益，但当前只有一个种子的完整分项结果，故不代替两种子原始框作为正式报告值。

3.5 PRISM无任务训练变体

PRISM面向完全冻结SAM2，包括三项规则：类别一致性过滤保留与最高置信候选类别相同的框；掩码反馈根据初次预测的外接框进行最多2轮调整，并按0.05比例外扩；当初始框面积超过图像面积25%时跳过反馈，以限制大框失控。该变体推理时不读取GT、不更新参数，也不增加MLLM调用。

PRISM在冻结SAM2上有效，但不作为NPA-SAM的必选前处理。分支化设计避免把在一种解码条件下有效的规则错误外推到另一种条件。

4 实验

4.1 数据集与指标

ORSSD包含600张训练图和200张测试图；EORSSD包含1,400张训练图和600张测试图；ORSI-4199包含2,000张训练图和2,199张测试图。主要指标包括结构度量Sα、最大F-measure、最大E-measure和平均绝对误差MAE。跨数据集平均采用三个数据集的等权算术平均，而非按2,999张测试图加权。

4.2 监督主结果

NPA-SAM两种子平均Sα如下。相比冻结SAM2直接使用原始MLLM框，监督轻量适配在三个数据集分别提高14.11、13.32和12.45点，宏平均提高13.30点。这一差值同时包含域内像素监督和提示分布适配的作用，不能全部归因于单一训练组件。

方法	训练标注	ORSSD Sα	EORSSD Sα	ORSI-4199 Sα	三集平均Sα
冻结SAM2+原始MLLM框	无	0.7805	0.7699	0.7351	0.7618
冻结SAM2+PRISM	无	0.7964	0.7949	0.7623	0.7845
NPA-SAM，两种子平均	**像素标注**	**0.9216**	**0.9031**	**0.8596**	**0.8948**

4.3 与全监督方法的性能位置

下表用于显示当前精度位置。MCCNet、SAM2-RS和IPDiff采用其论文报告值，GeleNet采用官方显著图在本文评测实现上的复评值；训练数据组织、输入分辨率和指标实现并未全部统一，因此不构成严格排名。

方法	ORSSD Sα	EORSSD Sα	ORSI-4199 Sα	三集平均Sα
MCCNet[1]	0.9437	0.9327	0.8746	0.9170
GeleNet[2]	0.9469	0.9376	0.8862	0.9236
SAM2-RS[3]	0.9546	0.9457	0.8854	0.9286
IPDiff[4]	0.9557	0.9461	0.8907	0.9308
NPA-SAM	**0.9216**	**0.9031**	**0.8596**	**0.8948**

NPA-SAM与IPDiff的宏平均差距为3.60点，与GeleNet的差距为2.88点。该差距明显小于冻结分支与全监督方法之间约14点的差距，说明把监督解码器提升为主方法是合理的；同时，现有结果仍不足以宣称超过全监督SOTA。

4.4 提示错误诊断

2,999张测试图共生成6,266个框。按与任一GT连通域外接框的最大IoU统计，2,958个框达到0.5，占47.2%；2,013个框低于0.1，占32.1%；其余1,295个处于0.1至0.5之间。提示框并集对GT前景的像素召回率平均为82.0%，而框内像素精确率仅38.4%，说明主要矛盾不是完全找不到前景，而是候选范围宽松、包含背景或选择了额外实例。

在ORSI-4199中，仅文件名类别可解析的1,660张图可用于类别分析。最高置信框类别与文件名映射类别一致的比例为91.3%；类别一致和不一致框的严格匹配率分别为67.7%和9.4%。该统计支持类别过滤，但不能推广到全部三集，也不能证明不同类别候选必然错误。

4.5 PRISM与适配解码器的组件交互

在最终seed42权重上，只改变推理规则进行匹配消融。类别过滤是唯一在三个数据集均产生正增益的组件；掩码反馈及完整组合未能保持冻结分支中的收益。

推理规则	ORSSD Sα	EORSSD Sα	ORSI-4199 Sα	宏平均Sα	相对原始框
原始MLLM框	0.9181	0.8998	0.8590	0.8923	-
仅类别过滤	0.9286	0.9096	0.8642	0.9008	+0.85点
仅掩码反馈	0.9165	0.8914	0.8557	0.8879	-0.45点
掩码反馈+面积守卫	0.9160	0.8906	0.8567	0.8878	-0.45点
类别过滤+反馈+守卫	0.9204	0.8976	0.8581	0.8920	-0.03点

类别过滤删除1,570个候选，其中44个与某个GT组件外接框IoU不低于0.5；21张图在过滤后失去全部此类框，这些图的平均Sα下降11.91点。由此可见，硬过滤整体有利，但对多类别显著场景存在集中风险。新版方法后续应把类别关系作为软评分，而不是继续扩大硬删除规则。

4.6 几何提示对照

固定网格双框和按文件名哈希生成的随机双框均不读取MLLM内容或GT。在最终seed42解码器上，原始MLLM框分别比固定和随机双框高2.77和2.27点；在冻结SAM2上差距更大。由于解码器是在MLLM式提示分布上训练的，该差值包含语义信息和训练-推理分布匹配的共同作用，不能全部命名为纯语义增益。

提示与解码器	ORSSD Sα	EORSSD Sα	ORSI-4199 Sα	宏平均Sα
固定网格双框+冻结SAM2	0.4584	0.4454	0.4396	0.4478
随机双框+冻结SAM2	0.4804	0.4660	0.4637	0.4700
固定网格双框+适配解码器	0.9041	0.8585	0.8312	0.8646
随机双框+适配解码器	0.9091	0.8630	0.8368	0.8696
原始MLLM框+适配解码器	0.9181	0.8998	0.8590	0.8923

4.7 留一数据集迁移

每一折只使用另外两个数据集的训练图像、训练掩码和训练提示统计，留出数据集只用于最终评测。三折宏平均0.8711，比对应域内配置低约2.04点，但比冻结PRISM高8.65点。这表明源域像素监督具有可迁移性，同时目标域训练仍提供稳定优势。

留出测试集	源域训练集	Sα	MAE
ORSSD	EORSSD+ORSI-4199	0.9016	0.0230
EORSSD	ORSSD+ORSI-4199	0.8799	0.0148
ORSI-4199	ORSSD+EORSSD	0.8317	0.0478
三集等权平均	-	**0.8711**	**0.0286**

4.8 提示oracle与剩余空间

在关闭PRISM并固定适配解码器的条件下，seed42原始框宏平均为0.8923，GT连通域框达到0.9158。两种子平均后，原始框和GT框分别为0.8948和0.9151，提示侧剩余空间为2.03点。删除错框、补充漏框和校正命中框范围在seed42上分别带来+0.27、+0.49和+0.43点，但三类干预相互重叠，不能相加。

GT框结果仍比GeleNet同评测实现的0.9235低约0.84点，说明即使提示理想化，冻结编码器和现有解码结构仍有剩余误差。因此后续工作不应继续把所有差距归因于MLLM提示。

5 讨论

5.1 为什么以监督适配作为最终方法

无任务训练PRISM验证了规则修复在冻结管线中的独立作用，但其宏平均0.7845与主流全监督方法存在较大差距。只训练4.22M参数的解码器即可把宏平均提高到0.8948，说明任务适配是当前系统中最主要的性能杠杆。将监督分支提升为主方法，能够使最终评分和论文方法定义一致；PRISM则承担低成本部署和机制对照的角色。

5.2 现有主方法的局限

第一，当前联合训练协议与主流逐数据集训练协议不完全一致，投稿前必须补做重复样本审计及逐数据集训练。第二，现有训练把多提示预测并集直接与整图GT比较，不能区分每个框对应哪个真值组件；错误提示可能通过其他正确提示被掩盖。第三，编码器完全冻结限制了遥感域适配上限，GT框oracle仍低于专用全监督模型。第四，测试集在方法开发过程中被多次评测，现有结果不能视为严格盲测。

5.3 下一步最具体的改进

最优先的改进是连通域级提示分配：训练时用匈牙利匹配将每个提示分配给某个GT组件，未匹配提示学习空目标，从而避免“多框并集对整图GT”掩盖错误。第二步是在SAM2编码器后两阶段加入少量LoRA或瓶颈适配器，同时保持早期层冻结。第三步把类别一致性从硬删除改为结合SAM2质量分、扰动一致性和掩码面积比的软有效性评分。这些模块完成实验前只能作为未来工作，不能把预期增益写入当前结果。

6 结论

本文研究冻结MLLM粗框与SAM2之间的噪声提示适配问题。通过从训练划分估计真实提示误差分布，并只训练4.22M参数的SAM2掩码解码器，NPA-SAM在ORSSD、EORSSD和ORSI-4199上取得0.9216、0.9031和0.8596的Sα，两种子宏平均为0.8948。无任务训练PRISM作为独立低成本分支，把冻结SAM2的宏平均从0.7618提高到0.7845；留一数据集训练达到0.8711。GT框oracle表明提示侧仍有2.03点空间，但理想提示仍不能完全追平专用全监督网络。

这些结果说明，真实噪声分布驱动的轻量任务适配比单纯扩大冻结主干或叠加规则更有效。当前稿件不宣称超过全监督SOTA，也不把联合训练结果包装为逐数据集同协议排名。后续研究将集中于组件级提示监督、软提示有效性建模和编码器后层的参数高效域适配。

参考文献

[1] LI G, LIU Z, LIN W, et al. Multi-content complementation network for salient object detection in optical remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5614513. DOI: 10.1109/TGRS.2021.3131221.

[2] LI G, BAI Z, LIU Z, et al. Salient object detection in optical remote sensing images driven by transformer[J]. IEEE Transactions on Image Processing, 2023, 32: 5257-5269. DOI: 10.1109/TIP.2023.3314285.

[3] SUN J, LIANG S, ZHAO Y. Unleashing the potential of segment anything model 2 for efficient salient object detection in optical remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2026, 64: 5620513. DOI: 10.1109/TGRS.2026.3689569.

[4] LI G, BAI Z, CONG R, et al. IPDiff: diffusion-driven ORSI salient object detection with information reconstruction and multi-prior guidance[J/OL]. arXiv:2607.03696, 2026.

[5] ZHAO W, LI X, MAO Z, et al. Is it time for the renaissance of salient object detection in the era of MLLMs?[J/OL]. arXiv:2607.29222, 2026.

[6] LI L, JI S, LUO Z, et al. Saliency-R1: incentivizing unified saliency reasoning capability in MLLM with confidence-guided reinforcement learning[J/OL]. arXiv:2511.00396, 2025.

[7] RAVI N, GABEUR V, HU Y T, et al. SAM 2: segment anything in images and videos[J/OL]. arXiv:2408.00714, 2024.

[8] HOU X, ZHANG L. Saliency detection: a spectral residual approach[C]//CVPR. 2007: 1-8. DOI: 10.1109/CVPR.2007.383267.

[9] ACHANTA R, HEMAMI S, ESTRADA F, et al. Frequency-tuned salient region detection[C]//CVPR. 2009: 1597-1604. DOI: 10.1109/CVPR.2009.5206596.

[10] FAN D P, CHENG M M, LIU Y, et al. Structure-measure: a new way to evaluate foreground maps[C]//ICCV. 2017: 4548-4557. DOI: 10.1109/ICCV.2017.487.

[11] FAN D P, GONG C, CAO Y, et al. Enhanced-alignment measure for binary foreground map evaluation[C]//IJCAI. 2018: 698-704. DOI: 10.24963/ijcai.2018/97.

[12] YUAN Y, LIU W, GAO P, et al. Unified unsupervised salient object detection via knowledge transfer[C]//IJCAI. 2024: 1616-1624. DOI: 10.24963/IJCAI.2024/179.

[13] YASARLA R, WENG R, CHOI W, et al. 3SD: self-supervised saliency detection with no labels[C]//WACV. 2024: 313-322. DOI: 10.1109/WACV57701.2024.00038.

[14] XING G, WANG M, WANG F, et al. Lightweight edge-aware Mamba-fusion network for weakly supervised salient object detection in optical remote sensing images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025, 63: 1-13. DOI: 10.1109/TGRS.2025.3587287.

[15] HUANG Z, XIANG T Z, CHEN H X, et al. Scribble-based boundary-aware network for weakly supervised salient object detection in remote sensing images[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2022, 191: 290-301.