MGRQ-Net：本地特化MLLM引导的可靠查询遥感显著性检测

新方法可实行方案报告（面向ORSSD、EORSSD与ORSI-4199）

0 执行摘要

本报告提出一条可真正实现、可逐步消融、并能与现有主流方法同协议比较的新方案：**MGRQ-Net（MLLM-Guided Reliable Query Network）**。其目标不是把MLLM当作外部粗框生成器，也不是简单串联“MLLM+SAM2”，而是让本地特化MLLM生成**带语义的目标查询**，再由可学习的可靠性判别、补漏查询和遥感适配分割器共同完成显著目标检测。

方法的核心矛盾是：MLLM擅长回答“图中什么可能显著”，但粗框存在错选、漏选和范围偏差；传统ORSI-SOD网络擅长像素预测，却缺少显式语义目标选择。MGRQ-Net把两者在查询层而非最终掩码层连接：MLLM候选查询负责提出目标，可靠性头负责拒绝错误候选，发现查询负责寻找MLLM遗漏目标，SAM2遥感适配主干和两阶段掩码解码器负责边界与细节。

本方案推荐以**本地开放权重MLLM为最终模型，API模型只作为数据教师和性能上界**。最终推理不依赖云端接口，便于复现、控制成本并使用MLLM中间语义特征。第一版最小可行模型只实现四个关键模块：本地MLLM离线查询、可靠性头、发现查询、SAM2后两阶段适配器。若该版本不能在相同训练协议下显著超过当前NPA-SAM的0.8948宏平均Sα，则停止增加复杂模块，优先检查数据协议、组件匹配和主干域适配。

> 一句话定义：MGRQ-Net用本地特化MLLM提出“可能显著的对象查询”，用可靠性学习决定“哪些查询可信”，用发现查询补回“MLLM没有看到的目标”，再由轻量适配的SAM2完成像素级分割。

1 研究目标与论文切入点

1.1 研究目标

在标准像素监督条件下，对光学遥感图像输出完整显著性掩码，并使MLLM成为模型中的有效语义模块，而不是仅在预处理阶段产生框。最终方法需同时满足四点：

1. 最终评分应接近主流全监督ORSI-SOD方法，而非停留在冻结基础模型水平。
2. 模型不能无条件相信MLLM提示，必须显式处理错框、漏框和多目标混合。
3. 最终推理应可离线完成，提示记录、模型权重和训练协议能够复现。
4. 每个创新模块都应有独立监督、明确数据流和可量化消融。

1.2 推荐论文切入点

推荐将论文问题定义为：**如何将本地特化MLLM的开放词汇语义判断转化为对遥感显著性检测有益且可拒绝、可补全的目标查询？**

这一切入点比“使用MLLM生成提示框，再交给SAM2”更强，原因在于：第一，MLLM语义进入查询解码器并参与目标竞争；第二，错误提示被监督为无目标，而不是依靠人工规则删除；第三，视觉发现查询为漏检提供独立恢复通路；第四，最终仍是端到端训练的显著性检测网络，可与MCCNet、GeleNet、SAM2-RS和IPDiff在相同监督协议下比较。

1.3 与当前工作的关系

当前NPA-SAM两种子宏平均Sα为0.8948，GT框oracle为0.9151，说明仅继续优化提示最多只能解释约2.03个点的空间；即使使用理想提示，现有冻结编码器和解码结构仍不足以完全追平强全监督方法。因此新方法必须同时解决**提示可靠性、漏检恢复和遥感视觉域适配**，不能只更换MLLM。

方法阶段	MLLM角色	漏检恢复	错提示处理	视觉域适配	方法上限
冻结MLLM+冻结SAM2	生成粗框	无	规则过滤	无	较低
NPA-SAM	生成训练/推理框	无独立通路	分布级适配	仅解码器	中等
MGRQ-Net	**生成语义查询**	**发现查询**	**可学习拒绝**	**编码器后层适配**	**面向全监督主流方法**

2 总体结构

2.1 数据流

输入图像首先由本地特化MLLM离线生成结构化候选，每个候选包含类别短语、粗框、显著理由和置信度。SAM2图像编码器提取四尺度视觉特征；MLLM候选经文本、位置和框内视觉特征融合形成语义候选查询。同时引入固定数量的可学习发现查询，它们不依赖MLLM，用于寻找遗漏目标。全部查询进入可靠查询解码器，输出目标存在概率、粗掩码和组件质量。粗掩码池化得到的目标特征再反向更新查询，第二阶段输出精细掩码。所有有效实例掩码经概率并集形成最终显著图。

> 图像 -> SAM2多尺度特征 -> 遥感适配器 -> 候选查询/发现查询 -> 可靠性判别与组件匹配 -> 两阶段掩码细化 -> 显著图

2.2 结构化MLLM输出

建议固定JSON格式，而不是让模型自由生成长文本：

scene_summary：一句话描述主要场景；candidates：最多5个候选，每个候选含phrase、bbox、saliency_reason和confidence；distractors：最多3个常见背景干扰物；empty_scene_probability：无显著目标概率。

推理时不使用MLLM生成像素掩码。框只提供粗位置，短语提供目标语义，干扰物短语用于构造负语义原型。离线缓存全部输出，避免训练期间反复加载MLLM或调用API。

2.3 候选查询构造

对第i个MLLM候选，构造查询：

$$q_i = W_t e_i^{text} + W_b e_i^{box} + W_v e_i^{roi} + e^{type_mllm}$$

其中，e_i^{text}为候选短语的本地MLLM文本特征，e_i^{box}为归一化框经位置MLP后的编码，e_i^{roi}为SAM2特征图上RoIAlign得到的视觉特征，e^{type_mllm}表示MLLM查询类型。三部分通过LayerNorm后相加，查询维度建议为256。

候选短语不能只保留15类硬标签。应保留“small airplane on runway”“isolated ship near harbor”等短语，使语义能够区分目标与背景关系。为控制噪声，可同时映射到一个粗类别词表，粗类别仅作为辅助监督。

2.4 发现查询

设置K=5个可学习发现查询：

$$d_k = e_k^{learn} + e^{type_discovery}$$

发现查询通过跨注意力直接读取整幅多尺度视觉特征，不使用MLLM框。训练时，未被任何MLLM候选正确覆盖的GT连通域优先分配给发现查询。这样，MLLM召回率不再决定网络召回率上限。

发现查询是本方案不可省略的关键。已有提示框并集对GT前景的平均召回约82%，如果没有独立补漏通路，剩余前景只能依靠框外扩张偶然恢复，难以形成稳定创新。

2.5 可靠性头

每个查询输出三项分数：目标存在概率p_obj、掩码质量p_iou和语义一致性p_sem。最终可靠性为：

r_i = sigmoid(MLP([q_i, p_obj, p_iou, p_sem]))

训练时，与GT组件匹配的查询监督为1；未匹配MLLM候选、背景候选和重复候选监督为0。推理时不做硬类别删除，而是以r_i连续调节实例掩码：

P(x) = 1 - product_i (1 - r_i * sigmoid(M_i(x)))

该概率并集能够保留多类别显著目标，也允许低可靠查询仅产生有限影响。相比“保留最高置信类别”的规则，这一设计具有明确监督并能处理一图多类。

2.6 SAM2遥感适配

采用SAM2.1 base+图像编码器。第一阶段冻结主干；第二阶段只在Hiera后两个stage插入瓶颈适配器或LoRA。推荐瓶颈适配器结构为LayerNorm -> Linear(256到64) -> GELU -> Linear(64到256)并带残差，早期层继续冻结。

适配目标不是重新训练整个SAM2，而是改善小目标、密集目标、任意方向结构和低对比背景的表征。若显存有限，只解冻后两个stage的归一化参数与适配器；不建议一开始全量微调。

2.7 两阶段查询-掩码细化

第一阶段生成粗实例掩码M_i^1。随后利用掩码加权池化得到目标特征：

z_i = sum_x sigmoid(M_i^1(x)) F(x) / sum_x sigmoid(M_i^1(x))

更新查询q_i^2 = q_i^1 + W_z z_i，并在高分辨率特征上输出M_i^2。该设计借鉴迭代细化思想，但只进行两次确定性前向，不采用完整扩散过程，从而控制计算量。

3 监督分配与损失函数

3.1 GT组件构造

将每幅GT显著图分解为连通域组件。过滤面积小于图像面积0.01%的孤立标注噪点，其余组件记录掩码、外接框、面积和中心。若两个组件由于标注相连而成为一个整体，则按原标注保留，不人为拆分。

3.2 匈牙利匹配

所有MLLM查询和发现查询共同参与一对一匹配。查询i与GT组件j的代价建议为：

C_ij = 2 L_dice + 2 L_bce + 1 L_box + 0.5 L_sem

其中，L_sem仅对MLLM查询启用；当数据集没有组件类别标注时，使用本地MLLM短语与图像组件裁剪之间的对比相似度作为弱语义项，不强行使用文件名标签。未匹配查询监督为无目标。对多个指向同一组件的重复MLLM候选，只允许一个成为正匹配，其余学习低可靠性。

3.3 总损失

推荐初始损失为：

L = L_mask + 0.5 L_boundary + 0.3 L_rel + 0.2 L_coverage + 0.1 L_cons

L_mask由BCE与Dice组成；L_boundary使用边界带上的加权BCE或Boundary IoU；L_rel为可靠性二分类损失，正负不平衡时使用Focal Loss；L_coverage约束每个GT组件至少被一个查询覆盖；L_cons约束轻度提示扰动前后的掩码一致性。

第一版不要同时加入过多新损失。实施顺序应为L_mask + L_rel，确认匹配正确后再加入边界、覆盖和一致性项。

3.4 提示扰动与MLLM dropout

训练时对MLLM候选执行三类扰动：20%概率删除正确候选，20%概率加入背景候选，30%概率对框进行中心和尺度扰动。同时以30%概率完全关闭MLLM候选，仅保留发现查询。该训练机制使网络不会把MLLM视为不可违背的真值。

MLLM dropout具有清晰的测试意义：如果关闭全部MLLM后模型性能完全崩溃，说明发现分支没有学到补漏；如果加入随机错误框后性能大幅下降，说明可靠性头未发挥作用。

4 本地特化MLLM方案

4.1 API与本地模型分工

最终论文主模型使用本地开放权重MLLM。API模型只承担三个角色：为训练图生成高质量场景描述、候选短语和干扰物；作为教师提供软置信度；作为提示源上界参与对照实验。API输出不得成为最终可复现结果的唯一依赖。

4.2 特化数据构造

每张训练图构造一个监督样本。候选短语可由API教师生成，但空间标签应由GT组件外接框校正，避免把教师的定位误差当作真值。训练样本包括：场景摘要、正候选短语与框、难负候选、漏检组件、无目标或弱显著场景描述。

建议数据配比为：50%正常正例，20%小目标/密集目标，15%复杂背景难负例，10%多类别显著图，5%近空场景。使用训练划分生成数据，测试图不得参与特化或提示模板选择。

4.3 参数高效微调

在显存受限条件下使用4-bit QLoRA，LoRA秩建议8或16，只注入视觉-语言投影层和高层注意力。训练目标是稳定输出结构化JSON和目标短语，不要求MLLM生成精细掩码。若本地设备只有8GB显存，选择2B至4B级视觉语言模型，输入长边448或576，批量1并使用梯度累积。

MLLM与SAM2无需同时驻留显存。先离线生成JSON和文本向量，再训练MGRQ-Net；最终部署也可把提示库预计算。如果要实现在线推理，可先运行MLLM并释放显存，再加载或调用常驻SAM2分割模块。

4.4 本地特化是否有效的判据

不要只比较框IoU。至少报告四项：GT组件召回率、错误候选比例、结构化输出成功率、最终分割Sα。若特化模型的框更准但最终Sα不升，说明查询网络已经能容忍框误差，后续不应继续投入MLLM定位微调。

提示源	是否可复现	是否可取中间特征	预期用途
无MLLM	是	不适用	视觉下界与必要性验证

提示源	是否可复现	是否可取中间特征	预期用途
本地基础MLLM	是	是	基线
本地特化MLLM	**是**	**是**	**最终主模型**
API教师	版本相关	通常否	数据教师与提示上界
GT组件框	不可部署	不适用	诊断oracle

5 可执行开发路线

5.1 阶段A：协议与数据审计（第1周）

固定三个数据集的官方训练/测试划分，计算文件哈希、感知哈希和标注相似度，重点排查ORSSD与EORSSD交叉重复。建立逐数据集训练与联合训练两套配置；论文主表优先采用与对比方法一致的逐数据集协议，联合训练作为补充。

输出物包括：数据清单、重复样本报告、统一指标脚本、当前NPA-SAM和一个纯视觉基线的可重复结果。必须先完成这一阶段，否则后续提高可能来自协议差异。

5.2 阶段B：最小可行MGRQ（第2至3周）

冻结SAM2图像编码器，使用现有MLLM JSON；实现连通域分解、查询构造、匈牙利匹配、可靠性头和5个发现查询。只训练查询解码器与掩码解码器，损失仅使用BCE、Dice和可靠性Focal Loss。

阶段验收条件：训练损失稳定下降；随机抽取至少100张图可视化查询-GT匹配；错误候选可靠性显著低于正确候选；关闭MLLM后发现查询仍能输出合理目标。

5.3 阶段C：遥感域适配（第4周）

在SAM2后两个stage加入适配器。先冻结解码器训练适配器1个epoch，再联合训练适配器与解码器2至4个epoch。若显存不足，保持输入分辨率不变，使用梯度检查点和混合精度，不要通过大幅降低分辨率牺牲小目标。

阶段验收条件：GT框oracle相对仅解码器版本明显提高；小目标子集和低对比子集改善；参数量和FLOPs可报告。

5.4 阶段D：本地MLLM特化（第5周）

使用训练集与API教师构造指令数据，通过QLoRA微调本地MLLM。离线重生成候选和文本特征，保持MGRQ其余部分不变重新评测。若本地特化只改善框指标但不改善最终显著图，则将其保留为附加实验，不继续扩大语言模型。

5.5 阶段E：两阶段细化与论文实验（第6至7周）

加入掩码池化查询更新和第二阶段精细掩码。完成两种子或三种子实验、效率测试、鲁棒性测试、错误案例与可视化。所有超参数先在训练集内部验证划分确定，再在测试集上一次性报告。

6 推荐训练配置

项目	初始配置
分割主干	SAM2.1 base+
输入分辨率	保持宽高比，长边1024；显存不足时768作为消融
MLLM候选数	最多5个
发现查询数	5个
查询维度	256
优化器	AdamW
解码器学习率	1e-4
适配器学习率	5e-5
权重衰减	0.05
训练轮数	先3至5 epoch，按验证集早停
批量	有效batch 8；显存不足用梯度累积
精度	BF16优先，无法支持时FP16
随机种子	至少42、43；最终关键表建议3种子
候选融合	可靠性加权概率并集

在8GB显存上，建议离线完成MLLM；SAM2训练使用batch 1、梯度累积8、混合精度和梯度检查点。若仍超显存，先减少发现查询和解码层数，而不是缩小到无法保留遥感小目标的输入尺寸。

7 必做实验矩阵

7.1 主结果

在ORSSD、EORSSD和ORSI-4199上报告Sα、maxF、maxE和MAE，并与MCCNet、GeleNet、SAM2-RS、IPDiff及当前NPA-SAM比较。训练协议必须逐项注明；若引用他文数值，不能将不同训练组织的结果包装为严格同协议排名。

7.2 核心消融

编号	模型	验证问题
A0	纯视觉SAM2适配器+解码器	不使用MLLM时的强基线
A1	A0+MLLM框查询	粗位置是否有用
A2	A1+短语语义特征	MLLM语义是否超过几何框
A3	A2+可靠性头	能否拒绝错提示
A4	A3+发现查询	能否补回漏检目标
A5	A4+后层适配器	遥感域适配增益
A6	A5+两阶段细化	边界与结构增益
A7	A6+本地MLLM特化	特化是否传导到最终评分

论文最重要的对比是A0与A2/A4。如果加入MLLM后相对强视觉基线没有稳定提升，就不能把MLLM作为主要贡献；应回到语义融合和匹配机制，而不是只展示提示框案例。

7.3 提示鲁棒性

测试四种干预：随机删除30%正确候选、加入1至3个背景候选、框中心偏移10%至30%、完全关闭MLLM。比较无可靠性头、硬类别过滤和可靠性头三种策略。预期结论应是：可靠性头在错提示条件下降幅更小，发现查询在删提示条件下保持更高召回。

7.4 语义真实性验证

为证明增益不是单纯来自额外框位置，设置三项对照：保留框但打乱候选短语；保留短语但随机交换框；使用与MLLM候选数相同的随机框。只有正确短语与正确局部视觉配对稳定优于这些对照，才能支持“MLLM语义引导”的论断。

7.5 效率实验

分别报告在线和离线两种成本。离线模式报告分割网络参数量、可训练参数、FLOPs、单图时间和提示库大小；在线模式额外报告本地MLLM生成时间和峰值显存。不能把离线缓存后的速度称为完整端到端速度。

8 成功判据与停止条件

当前可用基线为NPA-SAM宏平均Sα 0.8948，主流方法约为0.9170至0.9308。新方法不应预先宣称具体提升，但可设置工程决策阈值：

1. 最小可行MGRQ相对NPA-SAM至少获得稳定正增益，且两种子方向一致。
2. 加入MLLM语义后必须优于“相同框+打乱短语”，否则语义创新未被证明。
3. 可靠性头在加入背景候选时应显著降低性能跌幅。
4. 发现查询应提高MLLM漏检组件的召回，并改善完全关闭部分提示时的表现。
5. 遥感适配器应提高GT框oracle；否则它没有解决视觉表示瓶颈。

若A0纯视觉强基线已经达到或超过完整MGRQ，而MLLM仅增加复杂度，则应诚实调整论文定位：MLLM作为可解释辅助分支，而不是性能核心。若可靠性头不能区分正负候选，应首先检查匈牙利匹配、负样本构造和类别不平衡，而不是继续叠加新模块。

9 主要风险与应对

9.1 MLLM特化过拟合数据集类别

风险表现为本地MLLM只记住机场、船舶等高频词，跨数据集泛化下降。应保留开放短语，加入同义表达和背景难负例，并用留一数据集训练验证迁移能力。

9.2 发现查询退化为普通全图分割

如果发现查询包揽全部目标，MLLM查询会失去作用。可在训练前期规定未被MLLM正确覆盖的组件优先分配给发现查询；对MLLM正确命中的组件给予候选查询较低匹配代价，但不在推理时强制。

9.3 可靠性头只学习框IoU

可靠性不应等同于框质量。一个宽松框可能仍指向正确显著对象，一个位置准确的背景框仍应拒绝。训练标签以组件匹配和最终掩码有效性为主，框IoU只作为代价项之一。

9.4 联合训练协议造成数据泄漏争议

必须完成跨数据集重复审计，并提供逐数据集训练结果。联合训练可作为“多源训练”设置单列，不与只使用单一训练集的方法直接比较。

9.5 模块过多导致贡献分散

论文主贡献保持三项：语义候选查询、可靠性拒绝、发现查询补漏。后层适配器和两阶段细化属于实现支撑，不要把每个小模块都包装成独立创新。

10 推荐论文叙事

建议题目为：**Local-MLLM Guided Reliable Query Learning for Salient Object Detection in Optical Remote Sensing Images**。

摘要中的核心逻辑应为：传统ORSI-SOD缺少显式目标语义，直接采用MLLM粗提示又会受到错选和漏选限制；本文将本地特化MLLM输出转换为语义候选查询，通过组件级匹配学习查询可靠性，并用视觉发现查询补充未被语言模型覆盖的目标；轻量适配的SAM2与两阶段掩码解码器进一步恢复遥感边界细节。

贡献建议只写三条：

1. 提出MLLM语义候选查询，使开放词汇场景理解直接参与ORSI-SOD的目标解码，而不是停留在外部框预处理。
2. 提出组件级可靠查询学习，对错误和重复提示进行可学习拒绝，并以发现查询恢复MLLM遗漏目标。
3. 构建可复现的本地MLLM与轻量SAM2适配流程，并通过语义打乱、提示污染、提示缺失和跨数据集实验验证各模块作用。

11 最小代码组织建议

文件/模块	职责
tools/build_mllm_cache.py	读取图像并生成固定JSON与文本向量
datasets/component_targets.py	GT连通域分解、框和边界目标
models/query_builder.py	文本、框与RoI特征融合
models/reliable_query_decoder.py	查询交互、可靠性和组件掩码
models/discovery_queries.py	可学习补漏查询
models/sam2_adapters.py	Hiera后两阶段适配器
losses/hungarian_matcher.py	组件级一对一分配
losses/mgrq_losses.py	掩码、边界、可靠性、覆盖损失
train_mgrq.py	分阶段训练与断点恢复
eval_sod.py	Sα、F、E、MAE统一评测
analysis/prompt_robustness.py	删除、污染、偏移和语义打乱实验

每次实验保存完整配置、Git提交、数据清单哈希、随机种子、提示缓存版本和评测脚本版本。MLLM输出缓存也应记录模型标识、量化方式、LoRA权重哈希与提示模板。

12 最终建议

最值得优先实现的不是更大的MLLM，也不是在现有PRISM上继续增加提示规则，而是**组件级可靠查询学习+发现查询**。这两个模块直接对应现有系统已经测出的两类缺陷：约三分之一候选严重失配，以及提示并集仍存在前景漏检。随后用SAM2后层适配器提高理想提示条件下的视觉上限。

建议采用"先证明机制，再追求分数"的顺序：先以现有MLLM缓存完成MGRQ最小版本，验证可靠性和补漏；再加入视觉域适配；最后才训练本地MLLM。这样即使本地MLLM微调效果有限，论文仍保留完整的、与提示源无关的可靠查询贡献。

附录A 首轮实验优先级

优先级	实验	预计工作量	决策价值
P0	数据重复审计+纯视觉强基线	2至3天	排除协议问题，建立真实下界
P0	组件匹配+可靠性头	4至6天	验证错提示是否可学习拒绝
P0	5个发现查询	2至4天	验证漏检能否恢复
P1	SAM2后两阶段适配器	3至5天	提高视觉表示上限
P1	提示污染/删除/语义打乱	2至3天	证明机制而非框数量
P2	本地MLLM QLoRA	5至8天	提升复现性与语义质量
P2	两阶段掩码细化	3至5天	改善边界和细结构

附录B 不应采用的表述

- 不应写"MLLM提供准确提示"，应写"MLLM提供带噪声的语义候选"。
- 不应写"端到端MLLM分割"，如果MLLM提示是离线缓存，应明确为两阶段可复现管线。
- 不应把GT框结果写成模型性能，它只能作为诊断oracle。
- 不应在没有语义打乱对照时把"框提示增益"全部归因于语言语义。
- 不应在不同训练数据组织下宣称严格SOTA。
- 不应预先在论文中填写尚未完成实验的预期分数。